

# DINOv2 照片识别测试报告

测试时间: 2025年2月13日  
模型: DINOv2 ViT-S/14  
设备: NVIDIA GeForce RTX 3090 Ti (CUDA)  
测试照片数: 4张

## 测试照片概览

本次测试使用了4张世界著名地标建筑的图片，检验 DINOv2 对真实世界图像的特征提取能力。

序号	文件名	地标名称	国家/地区	图片尺寸	文件大小
1	OIP-C (1).webp	悉尼歌剧院	澳大利亚悉尼	474×316	17.7 KB
2	OIP-C.webp	大本钟	英国伦敦	474×315	13.6 KB
3	Top100AttractionsInTheWorldA9.webp	世界景点合成图	全球	1024×1024	181.4 KB
4	istock000070396403medium.webp	泰姬陵	印度阿格拉	1240×930	122.0 KB

## 地标详细介绍

### 1. 悉尼歌剧院 (Sydney Opera House)

- 建造时间: 1959-1973年
- 建筑师: 约恩·乌松

- **特色:** 贝壳状屋顶设计，20世纪最具特色的建筑之一
- **世界遗产:** 2007年列入联合国教科文组织世界遗产名录

## 2. 大本钟 (Big Ben)

- **正式名称:** 伊丽莎白塔 (Elizabeth Tower)
- **建造时间:** 1843-1859年
- **高度:** 96米
- **特色:** 哥特复兴式建筑，世界最著名的钟楼之一

## 3. 世界景点合成图

- **包含地标:** 埃菲尔铁塔、自由女神像、罗马斗兽场、万里长城等
- **用途:** 旅游宣传海报
- **特点:** 多地标组合设计图

## 4. 泰姬陵 (Taj Mahal)

- **建造时间:** 1632-1653年
- **建造者:** 莫卧儿皇帝沙贾汗
- **特色:** 白色大理石陵墓，穆斯林艺术的瑰宝
- **世界遗产:** 1983年列入世界遗产名录

---

## 模型配置

---

### DINOv2 ViT-S/14 模型规格

参数	值
模型类型	Vision Transformer (ViT)
模型大小	Small (S)
Patch 大小	14×14 像素
输入尺寸	224×224 像素
特征维度	384 维
总参数量	22,056,576 (约2200万)

参数	值
Token 数	257 tokens/张 (256 patches + 1 class token)
预训练数据	LVD-142M 数据集
训练方式	自监督学习 (DINO + iBOT)

## 预处理流程

```

transforms.Compose([
    transforms.Resize(256),      # 短边调整为256
    transforms.CenterCrop(224),  # 中心裁剪224×224
    transforms.ToTensor(),       # 转为张量
    transforms.Normalize(        # ImageNet标准化
        mean=[0.485, 0.456, 0.406],
        std=[0.229, 0.224, 0.225]
    )
])

```



## 特征提取结果

### 每张图片的特征统计

照片	特征均值	特征标准差	特征最小值	特征最大值	特征范数
悉尼歌剧院	0.0036	2.4352	-6.5824	7.4447	47.7193
大本钟	0.0203	2.5159	-6.7478	7.6881	49.3033
世界景点合成	0.0209	2.4871	-6.6572	7.4984	48.7388
泰姬陵	-0.0157	2.5282	-6.8312	7.7842	49.5441

### 分析:

- 特征范数在 47.7-49.5 之间, 说明各图片特征激活强度相近

- 泰姬陵的特征范数最高（49.54），可能与其独特的白色大理石建筑特征有关
- 所有特征的均值接近0，符合预训练模型的归一化特性

## 相似度分析

### 余弦相似度矩阵

余弦相似度范围：-1（完全不同）到 1（完全相同）

照片	悉尼歌剧院	大本钟	世界景点合成	泰姬陵
悉尼歌剧院	1.000	0.077	<b>0.219</b>	0.117
大本钟	0.077	1.000	0.179	0.079
世界景点合成	<b>0.219</b>	0.179	1.000	<b>0.055</b>
泰姬陵	0.117	0.079	<b>0.055</b>	1.000

### 关键发现

#### 1. 最高相似度配对

悉尼歌剧院 ↔ 世界景点合成图 (相似度: 0.219)

- **原因分析:** 世界景点合成图中可能包含悉尼歌剧院元素，或两者共享类似的蓝天+建筑构图
- **特征共享:** 水边建筑、独特屋顶设计、蓝天背景

#### 2. 最低相似度配对

世界景点合成图 ↔ 泰姬陵 (相似度: 0.055)

- **原因分析:**
  - 世界景点合成图是多元素组合设计图
  - 泰姬陵是单景点摄影，具有独特的对称花园和水池倒影
  - 视觉风格差异极大（现代设计 vs 古典建筑摄影）

### 3. 整体相似度分析

统计指标	数值
平均相似度	0.1210
最高相似度	0.2194
最低相似度	0.0549
标准差	0.0523

#### 结论:

- 所有照片对的相似度都较低 ( $< 0.25$ )，说明 DINOv2 能够区分不同的地标建筑
- 地标建筑虽然同属"旅游景点"类别，但视觉特征差异明显
- 这符合预期：不同文化背景、建筑风格、摄影角度产生不同的视觉特征

## 相似度分组分析

阈值：相似度  $> 0.85$

结果: 没有超过0.85的相似照片组

这表明：

1. 4张照片都是独特的地标，没有重复或高度相似的图像
2. DINOv2 能够有效区分不同的建筑结构和视觉风格
3. 即使是同一类别（地标建筑），也能捕捉细微的差异

潜在分组（降低阈值至 0.15）

分组	照片	相似度	共同点
组1	悉尼歌剧院、世界景点合成	0.219	都包含悉尼歌剧院元素
组2	大本钟、世界景点合成	0.179	西方地标建筑

## 性能分析

### 处理速度

指标	数值
总处理时间	0.24 秒
平均每张	59.73 毫秒
吞吐量	16.74 张/秒
GPU 利用率	高

### 时间分解

模型加载: ~0.5秒 (首次运行, 已缓存)  
特征提取: ~0.06秒/张  
相似度计算: <0.01秒  
总计: ~0.24秒 (4张)

### 与几何形状测试对比

测试类型	平均处理时间	说明
几何形状 (10张)	23 ms/张	纯色背景, 特征简单
真实照片 (4张)	60 ms/张	复杂场景, 特征丰富

**分析:** 真实照片处理时间稍长, 可能是因为:

- 图像内容更复杂, 特征计算更密集
- 首次加载模型后缓存效应

# DINOv2 特征理解

---

## 特征向量特性

1. **高维稀疏性** (384维)
2. 每个维度捕捉不同的视觉概念
3. 稀疏激活：大部分值接近0，少数显著激活
4. **语义编码**
5. 不直接对应人类可理解的标签
6. 编码形状、纹理、颜色、结构等视觉信息
7. **对比性**
8. 相似视觉内容 → 高余弦相似度
9. 不同视觉内容 → 低余弦相似度

## 特征可视化概念

虽然无法直接可视化384维向量，但可以理解：

悉尼歌剧院特征 ≈ [贝壳形状，现代建筑，蓝色，水边，白色，独特屋顶，...]  
泰姬陵特征 ≈ [圆顶，古典建筑，白色大理石，对称，花园，倒影，...]

---

## 应用场景建议

---

基于本次测试结果，DINOv2 适合以下应用：

### 1. 图像检索系统

- 能够区分不同地标
- 可用于相似景点推荐

## 2. 重复图像检测

- 相似度阈值<0.85视为不同图像
- 可用于数据集去重

## 3. 图像聚类

- 根据视觉相似度自动分组
- 适合相册整理、内容分类

## 4. 地标识别

- DINOv2 是特征提取器，不是分类器
- 需配合分类头或检索数据库使用



## 技术细节补充

### Token 计算

输入分辨率: 224×224

Patch 大小: 14×14

Patches 数量:  $(224/14) \times (224/14) = 16 \times 16 = 256$

Class Token: 1

总 Tokens:  $256 + 1 = 257$

**4张照片总 Token 数:** 1,028 tokens

### 模型架构

输入图像 (224×224×3)

↓

Patch Embedding (14×14 patches)

↓

Position Embedding + Class Token

↓



Transformer Encoder × 12 layers

↓

Class Token Output (384-dim)

↓

特征向量 [batch, 384]

## 缓存信息

- **模型文件:** `~/.cache/torch/hub/checkpoints/dinov2_vits14_pretrain.pth` (85MB)
- **源码目录:** `~/.cache/torch/hub/facebookresearch_dinov2_main/`
- **总缓存大小:** ~90MB

## 结论

### 主要发现

1. **DINOv2 成功提取了4张地标照片的视觉特征**
2. 每张图片生成384维特征向量
3. 特征范数在47-50之间，分布合理
4. **地标建筑间视觉差异明显**
5. 平均相似度仅0.12
6. 最高相似度0.22（悉尼歌剧院 vs 合成图）
7. 能够有效区分不同建筑风格
8. **处理速度快**
9. 60ms/张（GPU）
10. 适合实时应用
11. **自监督特征的有效性**
12. 无需标注数据，自动学习视觉表示
13. 捕捉形状、纹理、结构等多维度信息

## 限制与注意事项

1. **不是分类器**: DINOv2 输出特征，不输出类别标签
2. **相似度相对性**: 0.2的相似度在不同数据集上含义不同
3. **预处理重要**: 必须使用与预训练相同的归一化参数

## 下一步建议

1. 扩大测试集（更多地标、不同光线条件）
2. 测试其他 DINOv2 变体（ViT-B/14, ViT-L/14）
3. 结合分类器进行地标识别任务
4. 探索特征可视化方法（t-SNE, PCA）

---

## 参考信息

- **DINOv2 论文**: "DINOv2: Learning Robust Visual Features without Supervision" (ICCV 2023)
- **官方仓库**: <https://github.com/facebookresearch/dinov2>
- **模型卡片**: [https://github.com/facebookresearch/dinov2/blob/main/MODEL\\_CARD.md](https://github.com/facebookresearch/dinov2/blob/main/MODEL_CARD.md)

---

报告生成时间: 2025年2月13日

测试环境: Ubuntu 22.04, PyTorch 2.7.0, CUDA 12.8